

WEEK 12

Image Classification & Land Cover Mapping

From Thresholds to Classifiers: Let the Machine Learn

THE CLASSIFICATION GAP

W8–W10 taught us to DETECT change. W12 teaches us to CLASSIFY what we see.



人類定規則（閾值法）→ 機器學規則（分類器）↑ 升級！

WHY CLASSIFICATION?

方法	輸入	輸出	限制
NDVI 閾值	1 個指標	2 類	不知道是「什麼」植被
SAR 閾值	1 個指標	2 類	只能分水/非水
K-means	6 個波段	K 類（無名稱）	分群無名稱
Random Forest	6 波段 + 訓練資料	N 類（有名稱）	需人類標記

類比：

閾值法 = 量血壓：「> 140 就是高血壓」—— 一個指標分兩類


K-means = 把病人的 10 項檢查丟給電腦：「幫我分 5 組」—— 不知道每組是什麼病

Random Forest = 給電腦 1000 個已確診的病歷：「學著分辨」—— 自動診斷新病人

FEATURE SPACE


每個像素有多個波段值 → 多維座標 → 同類地物會「聚在一起」

波段	Feature Space 角色	物理意義
B2 (Blue)	維度 1	藍光反射率
B3 (Green)	維度 2	綠光反射率
B4 (Red)	維度 3	紅光反射率
B8 (NIR)	維度 4	近紅外反射率
B11 (SWIR1)	維度 5	短波紅外
B12 (SWIR2)	維度 6	短波紅外



FEATURE SPACE VISUALIZATION

NDVI 閾值法 (1D)



→ 只能分 2 類

6-Band Feature Space

[B2, B3, B4, B8, B11, B12]

水體：NIR 低、SWIR 低

植被：NIR 高、Red 低

裸地：所有波段都中等


建物：SWIR 高、NIR 中

→ 同時分 N 類！

「 $NDVI = (NIR - Red) / (NIR + Red)$ 只是把 2D 壓縮成 1D。你丟失了一半的資訊。」

K-MEANS: THE ALGORITHM


非監督式分類 — 機器自己找分群, 不需要訓練資料



「K-means 就是『分組 → 算平均 → 重新分組 → 算平均 →』直到不再變化。」

K-MEANS: CHOOSING K

Elbow Method



實務考量

研究區有 5 種主要地物

→ K=5 是起點

但同一種地物可能有子類

(淺水 vs 深水)

→ K 可能要更大

最終還是需要人類判斷

LAB 1: K-MEANS CLASSIFICATION

35 minutes | Unsupervised Classification

Step 1: Load Sentinel-2 image (STAC API)

Step 2: Build feature matrix (6 bands, shape: n_pixels x 6)

Step 3: Run K-means with K=5

Step 4: Visualize classification map

Step 5: Analyze mean spectra per cluster

Step 6: Try K=7, K=10 and compare results

Goal: 體驗「機器自己找分群」的魔力，但也感受「不知道每群是什麼」的挫折

FROM UNSUPERVISED TO SUPERVISED

K-means 結果

Cluster 0
Cluster 1
Cluster 2
Cluster 3
Cluster 4

→ 每個群是什麼？不知道！



Random Forest 結果

- 水體 (Water)
- 森林 (Forest)
- 農田 (Cropland)
- 裸地/崩塌 (Bare)
- 建物 (Built-up)

→ 每個類別都有名字！

「如果我先告訴機器『這些是水、這些是森林』，它就能自動對所有像素分類，而且結果直接帶有類別名稱。」

TRAINING SAMPLES

Garbage In = Garbage Out — 訓練樣本的品質決定分類的品質

1

代表性

涵蓋每個類別的
光譜變異

2

分散性

分佈在研究區
各處，不只一角

3

純淨性

避免邊界像素
(如水/岸邊)

4


足量

每類至少
50-100 個像素

「Training sample 的重要性等同於實驗的量測數據。數據爛，模型再好也沒用。」

DECISION TREE

先教一棵樹，再講森林 — 每個分叉就是一個 if-else



「整棵樹就是一連串的if-else 規則 — 這些規則是機器從訓練資料中自動學出來的」

RANDOM FOREST

從一棵樹到一片森林 — 200 棵樹的集成智慧

Bagging

每棵樹用不同的
隨機子集訓練

Feature Random

每棵樹只看
 $\sqrt{6} \approx 2$ 個波段

Majority Vote

200 棵樹投票
多數決

200

n_estimators
(樹的數量)

$\sqrt{6}$

max_features
(每棵樹看的波段)

< 1 min

Training Time
(不需要 GPU)

Top-N

Feature Importance
(哪個波段最重要)

「一個專家可能判斷錯誤，但 200 個專家投票通常比一個人準。」

LAB 2: RANDOM FOREST CLASSIFICATION

35 minutes | Supervised Classification + Accuracy Assessment

Step 1: Select training samples (50+ pixels per class)

Step 2: Build X_{train} , y_{train} matrices

Step 3: 80/20 train-test split

Step 4: Train Random Forest ($n_{\text{estimators}}=200$)

Step 5: Classify entire image and visualize

Step 6: Confusion matrix + accuracy metrics

Step 7: Feature importance analysis

Key insight: 訓練樣本品質差 → 所有像素都分成同一類 → 檢查訓練資料！

CONFUSION MATRIX REVISITED

從 W9 的 2×2 升級到 W12 的 5×5

	W9 (2×2)	W12 (5×5)
類別數	2 (變化 / 沒變)	5 (水/森/農/裸/建)
對角線	正確分類	正確分類
非對角線	錯誤 (漏報/虛警)	哪兩個類別搞混
可以看到	漏報率、虛警率	更細膨的錯誤分析

5×5 Confusion Matrix 範例：

對角線越高越好（正確分類），非對角線告訴你哪些類別容易搞混

PRODUCER'S VS USER'S ACCURACY

指標	意義	防災意涵
Producer's Acc (Recall)	該類別有多少 被正確找到？	崩塌地的 recall 低 = 漏報崩塌
User's Acc (Precision)	被分為該類的 有多少是真的？	崩塌地的 precision 低 = 虛報崩塌
Overall Acc	全部像素中 正確比例	整體表現
Kappa	扣除隨機的 準確率	比 OA 更嚴格

「指揮官最在乎的：崩塌地的 recall 是多少？因為漏報 = 有人被困在瓦礫下。」

CLASSIFICATION REPORT 解讀

sklearn classification_report 的每個欄位都在告訴你什麼

指標	公式	意義	判斷基準
F1-score	$2 \times P \times R / (P + R)$	Precision 與 Recall 的調和平均	> 0.9 優良, > 0.8 可接受
Support	測試集像素數	該類別在測試集中的像素數量	< 30 個時指標不可信！
Macro avg	算術平均	各類別等權平均（對少數類別公平）	較低 → 少數類別表現差
Weighted avg	加權平均	依樣本數加權（大類主導）	較高 → 大類拉高平均

陷阱：Weighted avg 高 ≠ 模型好

當 Weighted avg (0.987) 與 Macro avg (0.947) 差距大，代表少數類別表現被多數類別「稀釋」。

例：Built-up 僅 21 個測試像素，F1=0.84，但因佔比小對 weighted avg 幾乎沒影響。

「看到 OA = 98% 別急著開香檳 — 先檢查每個類別的 F1 和 support。」

FEATURE IMPORTANCE & MEDIAN FILTER

特徵重要性 Feature Importance

計算方式： Mean Decrease in Impurity (MDI)

每棵樹的每次分裂都會降低 Gini impurity,
累加每個特徵貢獻的總降低量,
再對 200 棵樹取平均。

典型結果：

NIR > SWIR1 > SWIR2 → 植被/水體區分

Red > Green > Blue → 裸地/建物區分

中值濾波 Median Filter

原理： 3×3 窗格內取中位數

在分類圖中，每個像素被其 8 個
鄰居「投票」— 多數決。

為什麼不用平均值濾波？

分類圖是離散值 (0,1,2,3,4),
平均值會產生不存在的類別 (如 2.3),
中值濾波保證結果仍是有效類別。

「特徵重要性告訴你『哪個波段最有用』，中值濾波告訴你『單像素雜訊不可信』。」

ERROR ANALYSIS

哪些類別容易混淆？為什麼？

農田 ↔ 森林

NIR 都高（都是植被）

加入紋理特徵

裸地 ↔ 建物

光譜類似

加入 NDBI 指標

淺水 ↔ 陰影

都很暗

加入 NDWI 指標

進階解法：加入紋理特徵 (texture)、空間脈絡 (object-based classification)、或融合 SAR 資料

POST-PROCESSING

分類結果的「椒鹽雜訊」— 和 W10 SAR 的 speckle 同樣的思路

Before: Salt & Pepper

單像素錯誤散布全圖
「森林中突然出現一個水體像素」



After: Median Filter

`median_filter(class_map, size=3)`
平滑結果，去除單像素雜訊

W10 SAR: morphological cleanup (開運算 + 閉運算)

W12 分類: median filter (中值濾波)

→ 同樣的思路：後處理去除雜訊，保留真實的空間樣態

一張分類圖 = 所有後續分析的基礎圖資

1

崩塌面積估計

崩塌類別的
總面積（公頃）

2

農損評估

農田被分為裸地
= 農作物被沖毀

3

都市衝擊

建物類別面積減少
= 建物受損

4

避難所評估 (W3)

500m 內有多少
崩塌/裸地？

「分類圖的準確性決定所有後續分析的可信度。」

ARIA v8.0 ARCHITECTURE

The Classification Engine — 完整系統架構



從v5.0 到v8.0 : 光譜指標 → 變遷偵測 → SAR 融合 → 影像分類。每週一層新能力。

REFLECTION

*Thresholds are your
first ruler.*

*Classifiers are your
CT scanner.*

You are now a Classification Analyst.

「但分類器只是把像素分成類別 — 它不知道那是一棟建物還是一座橋。」
下一步升級：讓 AI 不只分類像素，還能辨識建物、道路、損壞區。

Next: W13 Remote Sensing AI — 從「分類像素」到「辨識物件」

「閾值法是你的第一把尺，分類器是你的 CT 掃描。但指揮官的判斷，永遠是最後一道防線。」